

Propuesta técnica extendida: modelo vectorial ReNoN para la transición energética sostenible en Azuay–Ecuador

Formulación de concentrador energético multivectorial, métodos de aprendizaje y optimización en la frontera del conocimiento, y simulaciones en MATLAB

Paquete de trabajo PT2 – Diseño del modelo multivectorial ReNoN (versión 2, extiende el reporte de julio de 2026)

Grupo de investigación GIEEC – DEET
Universidad de Cuenca

Cuenca, septiembre de 2026

Resumen

Este reporte extiende la propuesta técnica de julio de 2026 [2] del proyecto *Transición energética sostenible en Azuay–Ecuador mediante infraestructuras integradas* en tres direcciones. Primero, reformula el modelo ReNoN (*Renewable Network of Networks*) como un **concentrador energético vectorial** (*energy hub*, Geidl *et al.* [7]): un vector de portadores de entrada (hidro, FV, eólica, SNI, térmica local, combustible), un vector de servicios (electricidad, agua potable, movilidad) y un vector de almacenamientos (batería estacionaria, tanques de agua, baterías de vehículos eléctricos) acoplados por una matriz $\mathbf{C}(t)$ cuyo promedio anual se convierte en un indicador de diagnóstico; incorpora el vehículo-a-red (V2G) como séptima variable de decisión y define indicadores de emisiones, costo y resiliencia *por vector*. Segundo, integra los avances del proyecto a septiembre de 2026: el diagnóstico nacional 2003–2024 publicado en *Electronics* [3], la replicación completa de la metodología EnergyPLAN+MOEA del caso Trento con 15 000 escenarios y su aceleración por optimización bayesiana (qNEHVI, MOTPE) [4], y la revisión sobre gemelos digitales de microrredes en preparación para Elsevier. Tercero, evalúa en MATLAB cuatro familias de métodos en la frontera del conocimiento sobre el modelo vectorial: (i) un **autoencoder** para comprimir y generar escenarios diarios en un espacio latente de 8 dimensiones; (ii) **redes de Kolmogorov–Arnold (KAN)** como sustitutos interpretables del modelo (486 parámetros, $R^2 = 0,9998$ en CO_2), comparadas con un perceptrón multicapa y con un sustituto de **auto-atención**; (iii) el **Dream Optimization Algorithm (DOA)**, que iguala a PSO y supera a GA en un problema restringido y reconstruye el 95 % del hipervolumen de NSGA-II por escalarización de Tchebycheff; y (iv) un EMS con **atención temporal** cuyos pesos se sintonizan con DOA. Los resultados muestran que la solución de compromiso 2030 (283 MW FV, 150 MW eólica, 30 MW mini-hidro, 61 % de carga inteligente) reduce las emisiones en 21,9 % con 58,2 % de fracción renovable local; que el V2G no es seleccionado en el año tipo pero reduce la energía no suministrada en 38 % bajo sequía extrema; que el sustituto KAN permite recuperar el 94,7 % del hipervolumen con 78 % menos evaluaciones del modelo; y que, con las señales actuales, el llenado de valles ya es casi óptimo, por lo que la atención temporal aporta una ganancia marginal ($\leq 0,3\%$) que crecerá con tarifas horarias y mayor carga flexible.

Nomenclatura

Las tablas siguientes reúnen los acrónimos y todos los símbolos utilizados en las ecuaciones del reporte. Los vectores se escriben en negrita ($\mathbf{p}$), los escalares en cursiva (p_h) y los valores

medios anuales con barra ($\bar{C}$). Salvo que se indique lo contrario, las potencias están en MW, las energías en MWh, las emisiones en tCO₂ y los costos en USD.

Tabla 1: Acrónimos.

Acrónimo	Significado
AE	Autoencoder (autocodificador)
ARCERNNR	Agencia de Regulación y Control de Energía y Recursos Naturales No Renovables
CAPEX / OPEX	Costo de inversión (anualizado) / costo de operación
CENTROSUR	Empresa Eléctrica Regional Centro Sur C.A.
CRF	Factor de recuperación de capital (<i>capital recovery factor</i>)
DOA	<i>Dream Optimization Algorithm</i> (algoritmo de optimización de los sueños)
EMS	Sistema de gestión de energía (<i>energy management system</i>)
ENS	Energía no suministrada
ETAPA	Empresa Pública Municipal de Telecomunicaciones, Agua Potable, Alcantarillado y Saneamiento de Cuenca
FE	Factor de emisión (tCO ₂ /MWh)
FV	Fotovoltaico
GA	Algoritmo genético (<i>genetic algorithm</i>)
HV	Hipervolumen (indicador de calidad de un frente de Pareto)
ICE	Motor de combustión interna (<i>internal combustion engine</i>)
IPCC	Panel Intergubernamental sobre el Cambio Climático
KAN	Red de Kolmogorov–Arnold (<i>Kolmogorov–Arnold Network</i>)
LHS	Muestreo por hipercubo latino (<i>Latin hypercube sampling</i>)
MLP	Perceptrón multicapa (<i>multilayer perceptron</i>)
MOEA	Algoritmo evolutivo multiobjetivo
MOTPE	Estimador de Parzen multiobjetivo estructurado en árbol
NRMSE	Raíz del error cuadrático medio normalizado
NSGA-II	<i>Non-dominated Sorting Genetic Algorithm II</i>
PCA	Análisis de componentes principales
PME	Plan Maestro de Electricidad (Ecuador)
PSO	Optimización por enjambre de partículas (<i>particle swarm optimization</i>)
PT1–PT4	Paquetes de trabajo 1 a 4 del proyecto
qNEHVI	<i>q-Noisy Expected Hypervolume Improvement</i> (adquisición bayesiana)
ReNoN	<i>Renewable Network of Networks</i> (red de redes renovables)
SNI	Sistema Nacional Interconectado (red eléctrica nacional del Ecuador)
TOU	Tarifa horaria (<i>time of use</i>)
V2G	Vehículo-a-red (<i>vehicle-to-grid</i>)
VE	Vehículo eléctrico
VoLL	Valor de la carga perdida (<i>value of lost load</i>), costo de racionamiento

Tabla 2: Símbolos del modelo vectorial ReNoN, del EMS y de los indicadores.

Símbolo	Definición	Unidad / valor
<i>Índices y conjuntos</i>		

Símbolo	Definición	Unidad / valor
t	Hora del año tipo, $t = 1, \dots, H$	–
H	Número de horas del año tipo	8760
d	Día del año, $d = 1, \dots, 365$; $\mathcal{T}_d$ es el conjunto de sus 24 horas	–
h	Hora del día, $h = 0, \dots, 23$	–
$v \in \{e, w, m\}$	Índice de servicio (vector): electricidad, agua, movilidad	–
c	Índice de portador de entrada: h (hidro), pv (FV), w (eólica), SNI, th (térmica), fuel	–
<i>Vectores del concentrador energético</i>		
$\mathbf{p}(t)$	Vector de portadores de entrada $[p_h, p_{pv}, p_w, p_{SNI}, p_{th}, p_{fuel}]^\top$	MW
$\mathbf{L}(t)$	Vector de servicios $[L_e, L_w, L_m]^\top$ en electricidad equivalente	MW
$L(t)$	Carga eléctrica total servida, $L = \sum_v L_v$	MW
$\mathbf{E}(t)$	Vector de almacenamientos $[E_b, E_{tk}, E_{ev}]^\top$ (batería, tanques, VE)	MWh
$\mathbf{C}(t), \bar{\mathbf{C}}$	Matriz de acoplamiento horaria (3×6) y su promedio anual	–
$\mathbf{S}$	Matriz de acoplamiento de los almacenamientos (3×3)	–
$s_v(t)$	Participación del servicio v en la carga total de la hora t	–
$c_h(t), c_{pv}(t), c_w(t)$	Factores de planta horarios (hidro, FV, eólica)	0–1
$G(t)$	Generación renovable local total	MW
$n(t)$	Carga neta = carga fija – generación renovable	MW
$\lambda(t)$	Factor de emisión del SNI en la hora t	tCO ₂ /MWh
$\pi(t)$	Precio de la energía importada del SNI	USD/MWh
<i>Variables de decisión $\mathbf{x} = [P_{pv}, P_w, E_b, P_h^+, f_a, f_v, f_g]$</i>		
P_{pv}, P_w	Capacidad FV y eólica instalada	MW
E_b	Capacidad de la batería estacionaria	MWh
P_h^+	Capacidad nueva de mini-hidro de pasada	MW
f_a	Fracción del bombeo de agua que es diferible	0–0,8
f_v	Fracción de la flota de VE con carga inteligente	0–1
f_g	Fracción de los VE con carga inteligente que ofrecen V2G	0–1
<i>Parámetros técnicos</i>		
P_{h0}, P_{w0}, P_{pv0}	Parque existente hidro, eólico y FV	40, 50, 5 MW
$\bar{P}_{SNI}$	Límite de importación desde el SNI	250 (350 en 2050) MW
$\bar{P}_{th}, FE_{th}$	Potencia y factor de emisión de la térmica local	20 MW; 0,70 t/MWh
$q_w(t)$	Caudal de agua potable producido	m ³ /h
e_{trat}, e_{bomb}	Energía específica de tratamiento y de bombeo	0,06; 0,40 kWh/m ³
ϕ_b	Fracción del caudal que requiere bombeo	0,25
N_f, x_{VE}	Flota liviana y fracción electrificada (25 % en 2030, 90 % en 2050)	veh.; –

Símbolo	Definición	Unidad / valor
n_{ev}	Número de VE, $n_{ev} = x_{VE} N_f$	veh.
$k(t)$, e_{km}	Kilómetros recorridos por hora y consumo del VE	km/h; 0,20 kWh/km
FE_{ICE}	Emisión de un vehículo de combustión	0,25 kgCO ₂ /km
$E_{a,d}$, $E_{v,d}$	Energía flexible diaria de bombeo y de VE (día d)	MWh
$\bar{P}_a$, $\bar{P}_v$	Potencia máxima del bombeo diferible y de la carga inteligente	MW
$u_a(t)$, $u_v(t)$	Cargas flexibles asignadas por el EMS (bombeo, VE)	MW
η_b , P_b	Eficiencia por sentido y potencia de la batería ($P_b = E_b/3$)	0,95; MW
p_{plug} , δ	Potencia del cargador bidireccional y disponibilidad en punta	3,3 kW; 0,30
φ , η_{v2g}	Fracción máxima de la energía diaria VE descargable y eficiencia de ciclo V2G	0,20; 0,85
P_{v2g} , $E_{v2g,d}$	Potencia y energía diaria disponibles para V2G	MW; MWh
$p_{v2g}(t)$, $p_{rec}(t)$	Descarga V2G y recarga asociada	MW
$p_b(t)$	Potencia de la batería (> 0 descarga, < 0 carga)	MW
$p_{ENS}(t)$, $p_{vert}(t)$	Energía no suministrada y vertimiento renovable en la hora t	MW
<i>Parámetros económicos</i>		
r	Tasa de descuento del CRF	6 %
c_{pv} , c_w , c_h , c_b	Costos anualizados de FV, eólica, mini-hidro y batería	USD/kW-año; USD/kWh-año
c_{flex} , c_{sev}	Costo anual de habilitar bombeo diferible (por unidad de f_a) y carga inteligente (por VE)	1,2 MUSD; 25 USD
c_{th}	Costo variable de la térmica local	190 USD/MWh
c_{v2g} , c_{v2g}^{cap}	Degradación por V2G y cargador bidireccional anualizado	60 USD/MWh; 150 USD/veh-año
VoLL	Costo de la energía no suministrada	10 000 USD/MWh
<i>Objetivos e indicadores</i>		
J_1 , J_2	Emisiones totales (ktCO ₂ /año) y costo anual total (MUSD/año)	–
$\mathbf{F}(\mathbf{x})$	Vector de objetivos [J_1 , J_2]	–
e_v , c_v , r_v	Emisiones, costo y resiliencia asignados al vector v	kt; MUSD; –
E_v	Energía anual servida al vector v	GWh
κ	Índice de acoplamiento (fracción de la demanda desplazada en el tiempo)	–
R	Índice de resiliencia del sistema, $R = 1 - ENS / \sum_t L(t)$	–
$HV(\mathcal{F}; \mathbf{z}^{ref})$	Hipervolumen del frente $\mathcal{F}$ respecto del punto de referencia	–
<i>EMS con atención temporal</i>		
$\theta = [\alpha, \beta, \gamma, \tau]$	Pesos de carga neta, factor de emisión y precio, y temperatura del softmax	–
$\tilde{n}_h$, $\tilde{\lambda}_h$, $\tilde{\pi}_h$	Señales horarias normalizadas dentro del día (media 0, desviación 1)	–

Símbolo	Definición	Unidad / valor
s_h, a_h	Puntaje y peso de atención de la hora h	–
u_h	Energía flexible asignada a la hora h	MWh

Tabla 3: Símbolos de los métodos de aprendizaje y optimización.

Símbolo	Definición	Unidad / valor
<i>Autoencoder</i>		
$\mathbf{d}$	Vector de un día ($24 \text{ h} \times 4 \text{ variables}$)	$\mathbb{R}^{96}$
$\mathbf{z}$	Código latente	$\mathbb{R}^8$
$f_{\text{enc}}, f_{\text{dec}}$	Codificador y decodificador	–
μ_d, σ_d	Media y desviación por componente usadas para estandarizar $\mathbf{d}$	–
σ_z	Desviación estándar de los códigos latentes	–
$\epsilon^a, \epsilon^m, \epsilon^d$	Perturbaciones latentes anual, mensual y diaria	–
<i>Sustitutos (KAN, MLP, atención)</i>		
$\tilde{\mathbf{x}}$	Vector de decisión normalizado a $[-1, 1]$	–
$\phi_{ij}(\cdot)$	Función de activación aprendible en la arista $i \rightarrow j$ de la KAN	–
w_{ij}, c_{ijb}	Peso de la función base y coeficientes de spline de la arista $i \rightarrow j$	–
$B_b(\cdot)$	B-spline cúbico b -ésimo sobre la malla ($G = 5$ intervalos, orden $k = 3$)	–
$\mathbf{e}_i$	Token de la variable i en el sustituto de atención	$\mathbb{R}^8$
$\mathbf{q}_i, \mathbf{k}_j, \mathbf{v}'_j$	Consulta, clave y valor de la atención	$\mathbb{R}^8$
$A_{ij}, \mathbf{A}$	Peso de atención de i sobre j y su media en el conjunto de prueba	–
$R^2, \text{RMSE}, \text{MAE}$	Coefficiente de determinación, error cuadrático medio y error absoluto medio	–
<i>Optimización</i>		
$\mathbf{x}^L, \mathbf{x}^U$	Límites inferior y superior de las variables de decisión	–
N, T, m	Agentes, iteraciones y grupos del DOA	60; 49; 5
$p_{\text{ex}}, p_{\text{olv}}$	Fracción de iteraciones de exploración y probabilidad de olvido (DOA)	0,9; 0,3
$k_{\min}^{(g)}, k_{\max}^{(g)}$	Número mínimo y máximo de dimensiones olvidadas en el grupo g	–
$\mathcal{A}(\iota)$	Amplitud de perturbación en la iteración ι	$1 \rightarrow 0$
$\rho, J_1^{\max}$	Penalización y límite de emisiones del problema restringido	5 MUSD/kt; 415 kt
$\mathbf{w}, \mathbf{z}^*, \mathbf{r}$	Vector de pesos, punto ideal y rango de normalización de Tchebycheff	–
$\mathbf{z}^{\text{ref}}$	Punto de referencia del hipervolumen	–

1. Introducción, alcance y estado del proyecto

La propuesta aprobada [1] plantea diseñar y validar un modelo de integración energética multivectorial —electricidad renovable, agua potable y movilidad eléctrica— para la provincia del Azuay, con horizontes 2030 y 2050. La versión 1 de la propuesta técnica [2] trasladó la metodología EnergyPLAN+MOEA de Viesi *et al.* [5] al contexto andino y entregó una primera herramienta operativa en MATLAB (simulación horaria anual, EMS jerárquico y NSGA-II). Este documento responde a tres necesidades identificadas tras esa primera versión: (a) formalizar el modelo con un **enfoque vectorial** explícito que haga visible el acoplamiento entre redes, (b) incorporar los **avances del proyecto** logrados entre julio y septiembre de 2026, y (c) explorar métodos de modelado y optimización **en la frontera del conocimiento** que sean candidatos para el sistema de gestión de energía (EMS) comprometido como entregable del PT2 (febrero de 2027).

1.1. Avances del proyecto (julio – septiembre 2026)

1. **Diagnóstico nacional publicado (PT1, Act. 1.1–1.2).** Ortega, Minchala y Arévalo [3] caracterizaron la generación eléctrica ecuatoriana 2003–2024 con datos oficiales de los Planes Maestros de Electricidad: brecha persistente entre potencia instalada y efectiva, alta concentración hidroeléctrica, respaldo térmico insuficiente y subsidios fluctuantes a combustibles fósiles. El artículo estima series anuales de CO₂, CH₄ y N₂O según las directrices IPCC 2006 (con potenciales de calentamiento AR5) e introduce el término *Kraftnot* para las crisis de suministro por hidrología adversa. Estas series sustentan el perfil estacional del factor de emisión del Sistema Nacional Interconectado (SNI) usado en este modelo.
2. **Replicación de la metodología de referencia (PT2, Act. 2.2).** El técnico de investigación replicó de extremo a extremo el marco EnergyPLAN+MOEA [4, 6]: el modelo base 2016 de Trento reproduce el balance físico del artículo con diferencias inferiores al 8%; la optimización con NSGA-II sobre 14 variables de decisión y 15 000 escenarios (≈ 18 h) produjo un frente de Pareto de 150 soluciones que reproduce el punto de referencia 2030 (CO₂ 2,59 Mt). Además, la **optimización bayesiana** con la función de adquisición qNEHVI [15] alcanzó el mismo punto de equilibrio (CO₂ 1,14 Mt, costo 4191 M€) con solo 300 simulaciones (≈ 2 h), y el estimador de Parzen multiobjetivo (MOTPE) [16] lo hizo en ≈ 5 min. Esta evidencia motiva la línea de *modelos sustitutos* desarrollada en la Sección 5.3.
3. **Revisión sobre gemelos digitales (PT2, Act. 2.1).** El capítulo *Digital twin modeling of energy conversion processes in smart microgrids* (Minchala, Loza y Ordóñez; *Comprehensive Microgrids*, Elsevier, en revisión editorial) sintetiza 144 fuentes sobre gemelos de conversión eólica, FV, almacenamiento y electrónica de potencia, y sobre las tecnologías habilitantes (co-simulación, HIL, modelos híbridos física–datos). Ese marco justifica concebir el modelo ReNoN como un *gemelo de planificación* sincronizable con las mediciones de CENTROSUR y ETAPA.
4. **Gestión.** Se incorporó un nuevo ayudante de investigación (Telecomunicaciones), el sitio web reporta Sprint 3 y los entregables definitivos del PT1 (Reportes 1 y 2 y base de datos) tienen fecha ajustada al 30 de septiembre de 2026.

1.2. Preguntas que aborda esta versión

- ¿Cómo expresar el acoplamiento electricidad–agua–movilidad de forma que los resultados sean interpretables *por vector* y comparables con la literatura de sistemas multienergía [9, 10]?

- ¿Qué aportan, frente a los métodos de referencia (NSGA-II, PSO, GA, PCA, MLP), los métodos recientes de aprendizaje y optimización —autoencoders, KAN [19], atención [22] y DOA [14]— en las tareas concretas del proyecto: generación de escenarios, sustitución del modelo, optimización de capacidad y operación del EMS?
- ¿Qué configuración del flujo de trabajo (datos → escenarios → sustituto → optimizador → EMS) conviene adoptar para el entregable de febrero de 2027?

2. Formulación vectorial del modelo ReNoN

2.1. Concentrador energético multivectorial

Siguiendo el formalismo de concentradores energéticos [7, 8], el sistema Azuay se describe en cada hora t del año tipo ($t = 1, \dots, H$, con $H = 8760$) por tres vectores:

$$\mathbf{p}(t) = [p_h, p_{pv}, p_w, p_{\text{SNI}}, p_{\text{th}}, p_{\text{fuel}}]^\top(t), \quad (1)$$

$$\mathbf{L}(t) = [L_e, L_w, L_m]^\top(t), \quad (2)$$

$$\mathbf{E}(t) = [E_b, E_{\text{tk}}, E_{\text{ev}}]^\top(t), \quad (3)$$

donde:

- $\mathbf{p}(t)$ es el **vector de portadores de entrada** (MW): p_h es la generación hidroeléctrica local, p_{pv} la fotovoltaica, p_w la eólica, p_{SNI} la importación desde el Sistema Nacional Interconectado, p_{th} la térmica local de respaldo y p_{fuel} el combustible consumido por los vehículos de combustión, expresado en MW equivalentes;
- $\mathbf{L}(t)$ es el **vector de servicios** (MW): L_e es la demanda eléctrica “pura” (residencial, comercial e industrial), L_w la energía eléctrica requerida por el servicio de agua potable y L_m la requerida por la movilidad eléctrica;
- $\mathbf{E}(t)$ es el **vector de almacenamientos** (MWh): E_b la energía en la batería estacionaria, E_{tk} la energía equivalente almacenada en los tanques de agua (bombeo que puede diferirse) y E_{ev} la energía en las baterías de los vehículos eléctricos (VE).

Los servicios de agua y movilidad se convierten a electricidad equivalente mediante

$$L_w(t) = (e_{\text{trat}} + \phi_b e_{\text{bomb}}) q_w(t), \quad L_m(t) = x_{\text{VE}} e_{\text{km}} k(t), \quad (4)$$

donde $q_w(t)$ es el caudal de agua potable producido (m^3/h), $e_{\text{trat}} = 0,06$ y $e_{\text{bomb}} = 0,40 \text{ kWh}/\text{m}^3$ son las energías específicas de tratamiento y de bombeo, $\phi_b = 0,25$ es la fracción del caudal que requiere bombeo, x_{VE} es la fracción electrificada de la flota liviana (25 % en 2030 y 90 % en 2050), $e_{\text{km}} = 0,20 \text{ kWh}/\text{km}$ es el consumo del VE desde la red y $k(t)$ son los kilómetros recorridos por la flota en la hora t . La fracción $(1 - x_{\text{VE}})$ de la flota consume combustible y no pasa por el bus eléctrico. El balance del concentrador es

$$\mathbf{L}(t) = \mathbf{C}(t) \mathbf{p}(t) + \mathbf{S} \dot{\mathbf{E}}(t), \quad (5)$$

donde $\mathbf{C}(t) \in \mathbb{R}^{3 \times 6}$ es la **matriz de acoplamiento**: su elemento $C_{vc}(t)$ es la fracción del portador c que, en la hora t , se convierte en el servicio v (incluye la eficiencia de conversión); $\mathbf{S} \in \mathbb{R}^{3 \times 3}$ es la matriz de acoplamiento de los almacenamientos (la batería sirve a los tres servicios a través del bus eléctrico, los tanques sólo al agua y las baterías de VE a la movilidad y, con V2G, también al bus eléctrico); y $\dot{\mathbf{E}}(t)$ es la variación horaria de la energía almacenada (positiva al descargar). En el modelo implementado el bus eléctrico es el nodo de acoplamiento:

todos los servicios electrificados comparten la misma oferta, de modo que $\mathbf{C}(t)$ no se fija *a priori* sino que se reconstruye *a posteriori* a partir de las participaciones horarias:

$$\bar{C}_{vc} = \frac{\sum_{t=1}^H s_v(t) p_c(t)}{\sum_{t=1}^H L_v(t)}, \quad s_v(t) = \frac{L_v(t)}{\sum_{v' \in \{e, w, m\}} L_{v'}(t)}, \quad (6)$$

donde $s_v(t)$ es la **participación** del servicio v en la carga total de la hora t (adimensional, $\sum_v s_v = 1$) y $\bar{C}_{vc}$ es la fracción anual del servicio v cubierta por el portador c . La matriz $\bar{\mathbf{C}}$ (Figura 2) es la “huella vectorial” de cada escenario y permite comparar directamente con las métricas de sistemas multienergía de Mancarella [9].

2.2. Generación renovable, carga neta y balance horario

La generación renovable local $G(t)$ y la carga neta $n(t)$ son

$$G(t) = (P_{h0} + 0,9 P_h^+) c_h(t) + P_{pv} c_{pv}(t) + P_w c_w(t), \quad n(t) = L^{\text{fijo}}(t) - G(t), \quad (7)$$

donde $P_{h0} = 40$ MW, P_{pv} y P_w son las capacidades hidro existente, FV y eólica (MW), P_h^+ es la capacidad nueva de mini-hidro (MW, con factor de planta 90 % del perfil existente), $c_h(t)$, $c_{pv}(t)$ y $c_w(t)$ son los factores de planta horarios (0–1) y $L^{\text{fijo}}(t)$ es la parte de la carga que no puede desplazarse (demanda pura, tratamiento de agua, bombeo no diferible y carga de VE no inteligente). El balance horario que cierra el EMS es

$$L(t) - G(t) = p_b(t) + p_{v2g}(t) - p_{\text{rec}}(t) + p_{\text{SNI}}(t) + p_{\text{th}}(t) - p_{\text{vert}}(t) + p_{\text{ENS}}(t), \quad (8)$$

donde $L(t) = \sum_v L_v(t)$ es la carga total incluidas las cargas flexibles ya asignadas, $p_b(t)$ la potencia de la batería (positiva al descargar, negativa al cargar), $p_{v2g}(t)$ la descarga V2G, $p_{\text{rec}}(t)$ la recarga que la compensa, $p_{\text{SNI}}(t) \leq \bar{P}_{\text{SNI}}$ la importación (límite 250 MW; 350 MW en 2050), $p_{\text{th}}(t) \leq \bar{P}_{\text{th}} = 20$ MW la térmica local, $p_{\text{vert}}(t)$ el vertimiento (excedente renovable no aprovechable) y $p_{\text{ENS}}(t)$ la energía no suministrada.

2.3. Cargas flexibles como almacenamiento virtual y V2G

Las cargas flexibles del agua (bombeo diferible, habilitado por la autonomía de 12 h de los tanques) y de la movilidad (carga inteligente) se modelan como almacenamientos virtuales con restricción diaria de energía: para cada día d , con $\mathcal{T}_d$ el conjunto de sus 24 horas,

$$\sum_{t \in \mathcal{T}_d} u_a(t) = E_{a,d} = f_a E_{\text{bomb},d}, \quad \sum_{t \in \mathcal{T}_d} u_v(t) = E_{v,d} = f_v E_{\text{ev},d}, \quad 0 \leq u_a(t) \leq \bar{P}_a, \quad 0 \leq u_v(t) \leq \bar{P}_v, \quad (9)$$

donde $u_a(t)$ y $u_v(t)$ son las cargas flexibles de bombeo y de VE asignadas por el EMS (MW), $E_{\text{bomb},d}$ y $E_{\text{ev},d}$ son la energía diaria total de bombeo y de carga de VE (MWh), $f_a \in [0, 0,8]$ y $f_v \in [0, 1]$ son las fracciones flexibles (variables de decisión) y $\bar{P}_a$, $\bar{P}_v$ las potencias máximas de bombeo y de carga inteligente.

La novedad de esta versión es el **vehículo-a-red** (V2G) [11]: una fracción f_g de los VE con carga inteligente dispone de cargador bidireccional. La potencia y la energía diaria disponibles para descarga son

$$P_{v2g} = f_g f_v n_{\text{ev}} p_{\text{plug}} \delta, \quad E_{v2g,d} = \varphi f_g f_v E_{\text{ev},d}, \quad \sum_{t \in \mathcal{T}_d} p_{\text{rec}}(t) = \frac{1}{\eta_{v2g}} \sum_{t \in \mathcal{T}_d} p_{v2g}(t), \quad (10)$$

donde $n_{\text{ev}} = x_{\text{VE}} N_f$ es el número de VE (N_f la flota liviana), $p_{\text{plug}} = 3,3$ kW la potencia del cargador, $\delta = 0,30$ la fracción de VE conectados en el pico vespertino (18–22 h, única ventana de descarga), $\varphi = 0,20$ la fracción máxima de la energía diaria de los VE que puede descargarse

y $\eta_{v2g} = 0,85$ la eficiencia de ciclo descarga-recarga; la recarga p_{rec} se sitúa en las cuatro horas de menor carga neta del mismo día. El vector de decisión completo es

$$\mathbf{x} = [P_{pv}, P_w, E_b, P_h^+, f_a, f_v, f_g], \quad \mathbf{x}^L \leq \mathbf{x} \leq \mathbf{x}^U, \quad (11)$$

con los límites de la versión 1 ($P_{pv} \leq 300$, $P_w \leq 150$, $E_b \leq 300$, $P_h^+ \leq 30$ en 2030; 600, 300, 800, 60 en 2050) y $f_g \in [0, 1]$.

2.4. EMS jerárquico y variante con atención temporal

El EMS conserva la jerarquía de la versión 1: (1) asignación diaria de las cargas flexibles; (2) batería estacionaria, que carga con excedente renovable y descarga en déficit con potencia $P_b = E_b/3$ y eficiencia $\eta_b = 0,95$ por sentido; (3) descarga V2G en el pico; (4) importación del SNI; (5) térmica local; y (6) energía no suministrada como último recurso. Para el paso (1), dada la energía flexible del día E (bien $E_{a,d}$ o $E_{v,d}$) y su potencia máxima $\bar{P}$, se implementan dos políticas:

- **Llenado de valles** (v1): las 24 horas se ordenan por carga neta $n(t)$ creciente y se llenan sucesivamente hasta $\bar{P}$ hasta agotar E .
- **Atención temporal**: cada hora $h \in \{0, \dots, 23\}$ del día recibe un puntaje y un peso de atención

$$s_h = -\frac{\alpha \tilde{n}_h + \beta \tilde{\lambda}_h + \gamma \tilde{\pi}_h}{\tau}, \quad a_h = \frac{\exp(s_h)}{\sum_{h'=0}^{23} \exp(s_{h'})}, \quad u_h = E a_h, \quad (12)$$

donde $\tilde{n}_h$, $\tilde{\lambda}_h$ y $\tilde{\pi}_h$ son la carga neta, el factor de emisión y el precio del SNI de la hora h normalizados dentro del día (media 0 y desviación estándar 1), $\theta = [\alpha, \beta, \gamma, \tau]$ son los parámetros de la política ($\alpha, \beta, \gamma \geq 0$ ponderan cada señal y $\tau > 0$ es la temperatura del softmax: valores pequeños concentran la energía en pocas horas) y u_h es la energía asignada a la hora h . Un procedimiento iterativo de recorte a $\bar{P}$ y redistribución proporcional a a_h garantiza $0 \leq u_h \leq \bar{P}$ y $\sum_h u_h = E$. Es una atención de producto escalar [22] en la que la “consulta” es el vector de preferencias θ y las “claves” son las señales horarias; cuando $\tau \rightarrow 0$ y $\beta = \gamma = 0$ recupera exactamente el llenado de valles.

2.5. Objetivos e indicadores por vector

Los dos objetivos son las emisiones totales y el costo anual total:

$$J_1(\mathbf{x}) = 10^{-3} \left[\sum_{t=1}^H (\lambda(t) p_{SNI}(t) + FE_{th} p_{th}(t)) + (1 - x_{VE}) N_f d_a FE_{ICE} \right], \quad (13)$$

$$J_2(\mathbf{x}) = 10^{-6} \left[\underbrace{(P_{pv} - P_{pv0})c_{pv} + (P_w - P_{w0})c_w + E_b c_b + P_h^+ c_h + f_a c_{flex} + f_v n_{ev} c_{sev} + f_g f_v n_{ev} c_{v2g}^{cap}}_{\text{CAPEX de generación y almacenamiento}} + \underbrace{f_a c_{flex} + f_v n_{ev} c_{sev} + f_g f_v n_{ev} c_{v2g}^{cap}}_{\text{CAPEX de flexibilidad}} \right. \\ \left. + \sum_{t=1}^H (\pi(t) p_{SNI}(t) + c_{th} p_{th}(t) + VoLL p_{ENS}(t) + c_{v2g} p_{v2g}(t)) \right], \quad (14)$$

OPEX

donde J_1 se expresa en ktCO₂/año y J_2 en MUSD/año; $\lambda(t)$ (tCO₂/MWh) y $\pi(t)$ (USD/MWh) son el factor de emisión y el precio estacionales del SNI; $FE_{th} = 0,70$ tCO₂/MWh y $c_{th} = 190$ USD/MWh corresponden a la térmica local; $d_a = 11000$ km es el recorrido anual por vehículo y $FE_{ICE} = 0,25$ kgCO₂/km la emisión de un vehículo de combustión; c_{pv} , c_w , c_h (USD/kW-año) y c_b (USD/kWh-año) son los costos de inversión anualizados con el factor de

recuperación de capital a $r = 6\%$ más operación y mantenimiento; $c_{\text{flex}} = 1,2$ MUSD/año es el costo de habilitar el bombeo diferible por unidad de f_a , $c_{\text{sev}} = 25$ USD/VE-año el de la carga inteligente, $c_{\text{v2g}}^{\text{cap}} = 150$ USD/VE-año el cargador bidireccional, $c_{\text{v2g}} = 60$ USD/MWh la degradación por descarga V2G y $\text{VoLL} = 10\,000$ USD/MWh el costo de racionamiento. La *solución de compromiso* de un frente es la que minimiza la distancia al punto ideal del frente normalizado, $\min \|\tilde{\mathbf{F}}\|_2$ con $\tilde{F}_i = (J_i - \min J_i)/(\max J_i - \min J_i)$.

Los indicadores **por vector** se obtienen asignando las cantidades horarias a cada servicio según su participación $s_v(t)$ de la Ec. (6):

$$e_v = 10^{-3} \sum_t s_v(t) (\lambda(t) p_{\text{SNI}}(t) + F E_{\text{th}} p_{\text{th}}(t)) + [v = m] e_{\text{ICE}}, \quad \text{ENS}_v = \sum_t s_v(t) p_{\text{ENS}}(t), \quad r_v = 1 - \frac{\text{ENS}_v}{E_v}, \quad (15)$$

donde e_v (ktCO₂) son las emisiones del vector v , $[v = m]$ vale 1 sólo para la movilidad (que recibe además las emisiones e_{ICE} de la flota de combustión), ENS_v (MWh) es la energía no suministrada imputada al vector, $E_v = \sum_t L_v(t)$ (MWh) su energía anual y $r_v \in [0, 1]$ su resiliencia. El costo c_v se obtiene de forma análoga con el OPEX horario, prorrateando el CAPEX de generación por energía ($E_v / \sum_{v'} E_{v'}$) e imputando el CAPEX de flexibilidad al vector que lo origina. La ENS del agua se traduce a m³ dividiendo por $(e_{\text{trat}} + \phi_b e_{\text{bomb}})$ y la de movilidad a km dividiendo por e_{km} . Finalmente, el **índice de acoplamiento**

$$\kappa = \frac{\sum_{t=1}^H (u_a(t) + u_v(t) + p_{\text{v2g}}(t) + \max(-p_b(t), 0))}{\sum_{t=1}^H L(t)} \quad (16)$$

mide la fracción de la demanda anual que es desplazada en el tiempo por los acoplamientos entre vectores (cargas flexibles, V2G y carga de la batería); $\kappa = 0$ corresponde a un sistema sin flexibilidad.

3. Métodos en la frontera del conocimiento evaluados

3.1. Autoencoder para el espacio de escenarios

Cada día d se representa por un vector $\mathbf{d} \in \mathbb{R}^{96}$ que concatena, para sus 24 horas, la demanda eléctrica en por unidad de la media anual y los factores de planta FV, eólico e hidro. Un autoencoder [21] es un par de redes

$$\mathbf{z} = f_{\text{enc}}(\hat{\mathbf{d}}) = \mathbf{W}_2 \tanh(\mathbf{W}_1 \hat{\mathbf{d}} + \mathbf{b}_1) + \mathbf{b}_2, \quad \hat{\mathbf{d}}' = f_{\text{dec}}(\mathbf{z}) = \mathbf{W}_4 \tanh(\mathbf{W}_3 \mathbf{z} + \mathbf{b}_3) + \mathbf{b}_4, \quad (17)$$

donde $\hat{\mathbf{d}} = (\mathbf{d} - \boldsymbol{\mu}_d)/\boldsymbol{\sigma}_d$ es el día estandarizado por componente (media $\boldsymbol{\mu}_d$ y desviación $\boldsymbol{\sigma}_d$ del conjunto de entrenamiento), $\mathbf{z} \in \mathbb{R}^8$ es el **código latente**, las matrices $\mathbf{W}_1 \in \mathbb{R}^{64 \times 96}$, $\mathbf{W}_2 \in \mathbb{R}^{8 \times 64}$, $\mathbf{W}_3 \in \mathbb{R}^{64 \times 8}$ y $\mathbf{W}_4 \in \mathbb{R}^{96 \times 64}$ y los sesgos $\mathbf{b}_i$ son los parámetros (arquitectura 96–64–8–64–96) y $\hat{\mathbf{d}}'$ es la reconstrucción. Los parámetros minimizan el error cuadrático medio $\|\hat{\mathbf{d}}' - \hat{\mathbf{d}}\|^2$ con Adam (8000 iteraciones) sobre 7300 días de 20 años sintéticos; la calidad se mide en 1460 días de prueba con

$$\text{NRMSE} = \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\bar{y}}, \quad (18)$$

donde y_i son los valores originales de una variable (p.ej. las 24 horas de FV de todos los días de prueba), $\hat{y}_i$ los reconstruidos, n su número y $\bar{y}$ su media; se compara con PCA de 8 componentes. El espacio latente se usa como **generador de escenarios**: a los códigos $\mathbf{z}_d$ del año base se les suma una perturbación jerárquica

$$\mathbf{z}'_d = \mathbf{z}_d + \boldsymbol{\varepsilon}^a + \boldsymbol{\varepsilon}_{m(d)}^m + \boldsymbol{\varepsilon}_d^d, \quad (19)$$

$$\boldsymbol{\varepsilon}^a \sim \mathcal{N}(\mathbf{0}, (0,5 \boldsymbol{\sigma}_z)^2), \quad \boldsymbol{\varepsilon}^m \sim \mathcal{N}(\mathbf{0}, (0,35 \boldsymbol{\sigma}_z)^2), \quad \boldsymbol{\varepsilon}^d \sim \mathcal{N}(\mathbf{0}, (0,3 \boldsymbol{\sigma}_z)^2),$$

donde ε^a es común a todo el año (variabilidad interanual, p.ej. ENOS), $\varepsilon_{m(d)}^m$ es común a los días del mes $m(d)$, ε_d^d es independiente por día y σ_z es la desviación estándar de los códigos latentes. Decodificando $\mathbf{z}_d'$ se construyen 200 años sintéticos para Monte Carlo, que se contrastan con el Monte Carlo paramétrico de la versión 1.

3.2. Redes de Kolmogorov–Arnold como sustituto interpretable

Las KAN [19] sustituyen los pesos lineales del perceptrón por funciones univariadas aprendibles en las aristas. Una capa con n_{in} entradas x_i y n_{out} salidas y_j calcula

$$y_j = \sum_{i=1}^{n_{\text{in}}} \phi_{ij}(x_i), \quad \phi_{ij}(x) = w_{ij} \text{silu}(x) + \sum_{b=1}^{G+k} c_{ijb} B_b(x), \quad \text{silu}(x) = \frac{x}{1 + e^{-x}}, \quad (20)$$

donde ϕ_{ij} es la función de activación de la arista $i \rightarrow j$, w_{ij} el peso de la función base silu , B_b el b -ésimo B-spline cúbico ($k = 3$) sobre una malla uniforme de $G = 5$ intervalos en el dominio de la entrada, y c_{ijb} sus coeficientes; todos los w_{ij} y c_{ijb} son parámetros entrenables. Se implementó en MATLAB con diferenciación automática (`dlarray`) una KAN [7, 6, 2] (7 entradas, 6 neuronas ocultas, 2 salidas; 486 parámetros) que aproxima $\tilde{\mathbf{x}} \mapsto [J_1, J_2]$, con $\tilde{\mathbf{x}} = 2(\mathbf{x} - \mathbf{x}^L)/(\mathbf{x}^U - \mathbf{x}^L) - 1 \in [-1, 1]^7$ el vector de decisión normalizado y los objetivos estandarizados, a partir de 480 muestras de hipercubo latino [18] del espacio de decisión 2030 (120 de prueba). Se compara con un MLP [7, 32, 32, 2] (tangente hiperbólica; 1378 parámetros) y con el sustituto de auto-atención del apartado siguiente, con las métricas

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}, \quad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad \text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|, \quad (21)$$

donde y_i es el valor real de un objetivo en la muestra de prueba i , $\hat{y}_i$ el predicho y $\bar{y}$ la media de los valores reales. Las funciones ϕ_{ij} aprendidas son graficables y su desviación estándar sobre el dominio, sumada en j , se usa como importancia relativa de la variable i [20]. Siguiendo a Jin [17], el sustituto KAN se usa después dentro de NSGA-II para medir cuánto hipervolumen del frente real se recupera con una fracción de las evaluaciones.

3.3. Mecanismo de atención

Se emplea en dos niveles. (a) **Sustituto con auto-atención**: cada variable de decisión normalizada $\tilde{x}_i$ ($i = 1, \dots, 7$) se convierte en un *token* y una cabeza de atención de producto escalar [22] calcula

$$\mathbf{e}_i = \tilde{x}_i \mathbf{v}_i + \mathbf{b}_i, \quad \mathbf{q}_i = \mathbf{W}_q \mathbf{e}_i, \quad \mathbf{k}_j = \mathbf{W}_k \mathbf{e}_j, \quad \mathbf{v}'_j = \mathbf{W}_v \mathbf{e}_j, \quad (22)$$

$$A_{ij} = \frac{\exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{8})}{\sum_{j'=1}^7 \exp(\mathbf{q}_i^\top \mathbf{k}_{j'} / \sqrt{8})}, \quad \mathbf{z}_i = \mathbf{e}_i + \sum_{j=1}^7 A_{ij} \mathbf{v}'_j, \quad (23)$$

donde $\mathbf{e}_i \in \mathbb{R}^8$ es el token de la variable i ($\mathbf{v}_i$ y $\mathbf{b}_i$ son su vector de valor y su sesgo aprendibles), $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v \in \mathbb{R}^{8 \times 8}$ son las proyecciones de consulta, clave y valor, $A_{ij} \in [0, 1]$ es el **peso de atención** con que la variable i atiende a la j ($\sum_j A_{ij} = 1$) y $\mathbf{z}_i$ la salida con conexión residual; los siete $\mathbf{z}_i$ concatenados alimentan una capa densa de 32 unidades ($\tanh$) y una salida lineal de 2 objetivos (2194 parámetros en total). La matriz media $\bar{\mathbf{A}}$ sobre el conjunto de prueba (Figura 8) revela qué variables “atienden” a cuáles, información complementaria a la de la KAN. (b) **EMS con atención temporal** de la Ec. (12), cuyos cuatro parámetros θ se sintonizan con DOA minimizando el escalar

$$J_{\text{EMS}}(\theta) = J_2 + 0,2 J_1, \quad (24)$$

que pondera 1 ktCO₂ como 0,2 MUSD (orden de magnitud de un precio del carbono de 200 USD/t). La familia de arquitecturas tipo Transformer para series largas (p.ej. Informer [23]) queda identificada para el pronóstico de demanda con datos reales en el PT3.

3.4. Dream Optimization Algorithm

El DOA [14] es una metaheurística de 2025 inspirada en el sueño humano. Con una población de N agentes $\mathbf{x}^{(i)}$ repartidos en m grupos, durante T iteraciones $\iota = 1, \dots, T$, la reimplementación propia (`doa.m`) aplica:

1. *Memoria*: cada agente del grupo g parte del mejor de su grupo, $\mathbf{x}^{(i)} \leftarrow \mathbf{x}_g^*$.
2. *Olvido y suplementación*: se eligen al azar $k \in [k_{\min}^{(g)}, k_{\max}^{(g)}]$ dimensiones, con $k_{\min}^{(g)} = \lceil D/(8g) \rceil$ y $k_{\max}^{(g)} = \lceil D/(3g) \rceil$ ($D = 7$ el número de variables; los primeros grupos olvidan más); cada dimensión elegida j se “olvida” con probabilidad p_{olv} y se reemplaza por

$$x_j^{(i)} \leftarrow x_j^{(i)} + (2u - 1)(x_j^U - x_j^L) \mathcal{A}(\iota), \quad \mathcal{A}(\iota) = \frac{1}{2}(1 + \cos(\pi\iota/T)), \quad u \sim \mathcal{U}(0, 1), \quad (25)$$

donde $\mathcal{A}(\iota)$ es la amplitud de perturbación, que decrece de 1 a 0 con el progreso de la búsqueda.

3. *Intercambio de sueños*: con probabilidad $1 - p_{\text{olv}}$ la dimensión se copia de otro agente elegido al azar, $x_j^{(i)} \leftarrow x_j^{(l)}$.
4. *Explotación*: en la fracción final $1 - p_{\text{ex}}$ de las iteraciones todos los agentes se muestrean alrededor del mejor global, $\mathbf{x}^{(i)} \leftarrow \mathbf{x}^* + 0,05 \mathcal{A}(\iota) (\mathbf{x}^U - \mathbf{x}^L) \odot \boldsymbol{\xi}$, $\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Toda propuesta se acepta sólo si mejora al agente (aceptación codiciosa) y se proyecta a los límites. Se usaron $m = 5$, $p_{\text{ex}} = 0,9$ y $p_{\text{olv}} = 0,3$; no se utilizó el código de los autores. La implementación se validó en las funciones de prueba esfera-10 y Rastrigin-10 con $N = 50$, $T = 200$ (10 050 evaluaciones) y cinco semillas: en esfera-10 alcanza valores entre 6×10^{-7} y $3,4 \times 10^{-6}$ y en Rastrigin-10 alcanza el óptimo global $f^* = 0$ en cuatro de las cinco semillas (0,995 en la restante). Sobre el modelo ReNoN se evalúa en dos problemas:

- (a) **Mono-objetivo restringido**: minimizar el costo sujeto a un límite de emisiones, resuelto por penalización,

$$\min_{\mathbf{x}} J(\mathbf{x}) = J_2(\mathbf{x}) + \rho \max(0, J_1(\mathbf{x}) - J_1^{\max}), \quad \rho = 5 \text{ MUSD/kt}, \quad J_1^{\max} = 415 \text{ kt}, \quad (26)$$

frente a GA y PSO de *Global Optimization Toolbox* y a búsqueda aleatoria, con presupuesto idéntico de 3000 evaluaciones ($N = 60$, $T = 49$) y 6 semillas.

- (b) **Frente de Pareto por escalarización de Tchebycheff aumentada**: para cada vector de pesos $\mathbf{w} = [w_1, w_2]$ ($w_1 + w_2 = 1$; 12 vectores equiespaciados) se resuelve

$$\min_{\mathbf{x}} g(\mathbf{x}; \mathbf{w}) = \max_{i \in \{1, 2\}} w_i \frac{J_i(\mathbf{x}) - z_i^*}{r_i} + 0,05 \sum_{i=1}^2 \frac{J_i(\mathbf{x}) - z_i^*}{r_i}, \quad (27)$$

donde $\mathbf{z}^* = [370 \text{ kt}, 65 \text{ MUSD}]$ es un punto ideal aproximado y $\mathbf{r} = [180 \text{ kt}, 70 \text{ MUSD}]$ los rangos de normalización; cada problema se resuelve con DOA ($N = 24$, $T = 10$; 264 evaluaciones) y el conjunto de soluciones se compara con NSGA-II [12] mediante el **hipervolumen** [13]

$$\text{HV}(\mathcal{F}; \mathbf{z}^{\text{ref}}) = \text{rea} \left(\bigcup_{\mathbf{F} \in \mathcal{F}} \{\mathbf{y} : \mathbf{F} \leq \mathbf{y} \leq \mathbf{z}^{\text{ref}}\} \right), \quad (28)$$

es decir, el área del espacio de objetivos dominada por el frente $\mathcal{F}$ y acotada por un punto de referencia $\mathbf{z}^{\text{ref}}$ común (5 % por encima del máximo de cada objetivo entre los frentes comparados); un HV mayor indica un frente más cercano al ideal y mejor distribuido.

4. Implementación

Los módulos nuevos residen en `code/analysis/propuesta_tecnica/matlab_v2/` del repositorio del proyecto y reutilizan los parámetros y el generador de perfiles de la versión 1: `renon_params_v2.m` (V2G, atención, límites de 7 variables), `renon_hub.m` (despacho vectorial, matriz $\bar{C}$, indicadores por vector), `doa.m`, `hv2d.m` (hipervolumen), `surr_lib.m` (KAN, MLP, atención y entrenador Adam sobre `dlarray`) y los cinco experimentos `s1_hub.m` a `s5_attention_ems.m`, que exportan las figuras a `reporte/figs_v2/` y las tablas CSV a `resultados_v2/`. Con $f_g = 0$ y llenado de valles, `renon_hub` reproduce exactamente los resultados de la versión 1 (verificación de regresión). Una evaluación anual completa toma $\approx 2\text{--}3$ ms (MATLAB R2026a, Apple Silicon), NSGA-II con 2928 evaluaciones toma ≈ 6 s y el conjunto de experimentos ≈ 6 min con 12 procesos paralelos.

5. Resultados

5.1. Modelo vectorial: frentes, huella vectorial y V2G

La Tabla 4 resume la línea base y las soluciones de compromiso obtenidas con NSGA-II sobre las 7 variables. La Figura 1 compara los frentes con los de la versión 1: los hipervolumenes son prácticamente iguales (2030: 1211 vs. 1218; 2050: 3442 vs. 3466; diferencias $< 0,7\%$, dentro de la variabilidad estocástica del algoritmo) y $f_g \approx 0$ en toda la frontera. Es decir, **con los costos asumidos el V2G no es competitivo en el año tipo**: su beneficio en emisiones es marginal (415,5→414,7 kt) porque la energía que desplaza ya proviene en gran parte de importación de bajo factor de emisión, y su costo anual crece 3,8 % (Figura 4). El valor del V2G aparece **bajo sequía extrema**: para la solución 2030, pasar de $f_g = 0$ a $f_g = 1$ reduce la energía no suministrada de 17,6 a 10,8 GWh (-38%) y el costo de crisis de 288 a 224 MUSD (-22%), aportando 9,4 GWh/año de descarga. El V2G es, por tanto, una *opción de resiliencia* cuyo valor sólo se captura con objetivos o escenarios de estrés explícitos; se recomienda incluirlo en el PT3 como tercer objetivo (resiliencia) o como restricción probabilística de ENS.

Tabla 4: Modelo vectorial: configuraciones e indicadores por vector (año tipo).

	Base 2024	ReNoN 2030	ReNoN 2050
FV / eólica / bat. / mini-hidro (MW, MW, MWh, MW)	5 / 50 / 0 / 0	283 / 150 / 0 / 30	600 / 300 / 19 / 60
f_a / f_v / f_g	–	0,19 / 0,61 / 0,00	0,05 / 0,99 / 0,00
CO ₂ total (kt/año) [Δ vs. base]	532,0	415,5 [$-21,9\%$]	226,7 [$-57,4\%$]
Costo anual (MUSD/año)	73,9	90,8	164,4
Fracción renovable local	25,7 %	58,2 %	63,4 %
Índice de acoplamiento κ	0,000	0,030	0,124
Energía por vector [E_e, E_w, E_m] (GWh)	[1300; 11,1; 2,9]	[1534; 12,1; 77,0]	[2340; 16,1; 326,7]
Emisiones por vector (ktCO ₂)	[176,2; 1,5; 354,3]	[121,4; 0,8; 293,3]	[168,2; 1,0; 57,4]
Costo por vector (MUSD)	[73,1; 0,6; 0,2]	[85,8; 0,8; 4,2]	[144,3; 1,0; 19,1]
Resiliencia por vector	[1; 1; 1]	[1; 1; 1]	[1; 1; 1]

La huella vectorial $\bar{C}$ (Figura 2) hace explícita la transición: en 2024 el 74 % de la electricidad y el 72 % del agua dependen del SNI, y el 99 % de la movilidad del combustible; en 2030 el SNI cae al 42 % (electricidad) y 34 % (agua) mientras FV y eólica cubren 37–44 %; en 2050 la movilidad electrificada al 90 % se alimenta 40 % de FV —las horas diurnas de carga inteligente coinciden con el recurso solar— y sólo 18 % del SNI. Obsérvese que el vector agua está sistemáticamente *más* descarbonizado que la electricidad pura porque el bombeo diferible se desplaza hacia las horas renovables: el acoplamiento agua–electricidad es el que primero captura el excedente FV. El vector agua representa menos del 1 % de la energía y del costo (Figura 3), pero su flexibilidad




Figura 1: Frentes de Pareto 2030 y 2050: versión 1 (6 variables) frente a la versión vectorial (7 variables, con V2G). HV: hipervolumen respecto de un punto de referencia común.

(tanques) es la más barata del sistema; el vector movilidad concentra el 71 % de las emisiones en 2030 y su electrificación explica el 78 % de la reducción 2030→2050.




Figura 2: Matriz de acoplamiento media $\bar{C}$ (fracción de cada servicio cubierta por cada portador) para la línea base y las soluciones de compromiso.

5.2. Autoencoder de escenarios

Con 8 dimensiones latentes el autoencoder reconstruye los días de prueba con NRMSE de 2,8 % (demanda), 10,4 % (eólica) y 1,1 % (hidro), idéntico a PCA (2,7 %, 10,4 %, 1,0 %), pero peor en FV (16,3 % vs. 8,2 %) (Tabla 5, Figura 5). El resultado es esperable: los perfiles sintéticos de la versión 1 se generan por productos de formas diarias, factores mensuales y ruido gaussiano, una estructura casi lineal en la que PCA es cercana al óptimo y explica el 96,4 % de la varianza con 8 componentes. La ventaja del autoencoder no está en la compresión sino en la **generación**: el muestreo latente jerárquico produce años sintéticos cuya distribución de resultados, evaluados con **renon_hub** sobre la solución de compromiso 2030 de la versión 1 (CO₂ mediana 417,8 kt, P5–P95 401–435; costo 90,2 MUSD, 83–98), coincide con la del Monte Carlo paramétrico (422,7 kt, 400–443; 92,1 MUSD, 82–101) sin haber especificado ninguna distribución de perturbaciones: la variabilidad interanual emerge de los datos. El espacio latente muestra separabilidad estacional




Figura 3: Emisiones y costo anual asignados por vector.




Figura 4: Sensibilidad a la fracción V2G f_g para la solución de compromiso 2030: valor bajo sequía extrema (izq.) y costo en el año tipo (der.).

(varianza entre meses / total = 0,22 en z_1). Con las series reales de CENTROSUR, ETAPA y el recurso medido (PT1), donde las no linealidades (nubosidad, régimen de lluvias, feriados) sí son relevantes, se espera que el autoencoder supere a PCA; ese contraste es una prueba de aceptación propuesta para el Sprint 5.

Tabla 5: Reconstrucción de días de prueba (NRMSE, %) con 8 dimensiones latentes.

	Demanda	FV	Eólica	Hidro
Autoencoder 96-64-8-64-96	2,77	16,27	10,42	1,09
PCA (8 componentes, 96,4 % var.)	2,75	8,20	10,41	1,01




Figura 5: Autoencoder de escenarios: reconstrucción de un día de prueba (arriba), espacio latente coloreado por mes (abajo izq.) y Monte Carlo del modelo hub con años generados por muestreo latente frente al Monte Carlo paramétrico (abajo der.).

5.3. Modelos sustitutos: KAN, MLP y atención

Los tres sustitutos aproximan el modelo hub con precisión suficiente para optimización (Tabla 6, Figura 6): errores de 0,3–0,7 ktCO₂ y 0,3–0,7 MUSD sobre rangos de 100 kt y 70 MUSD. La KAN alcanza $R^2 = 0,9998$ en CO₂ con **3,5 veces menos parámetros** que el MLP y 4,5 veces menos que el modelo de atención, aunque es la menos precisa en costo ($R^2 = 0,995$; los puntos de mayor costo, con batería grande, quedan fuera de la malla de splines) y la más costosa de entrenar en nuestra implementación no optimizada (38 s). El sustituto de atención es el más preciso en ambos objetivos.

Interpretabilidad. Las funciones $\phi_{1j} \dots \phi_{7j}$ de la primera capa de la KAN (Figura 7) y su desviación estándar como medida de importancia ordenan las variables: carga inteligente f_v (29 %), eólica P_w (24 %), FV P_{pv} (16 %), mini-hidro P_h^+ (14 %), V2G f_g (9 %), batería E_b (7 %)

Tabla 6: Sustitutos del modelo hub (2030), 480 muestras de entrenamiento y 120 de prueba. Los tiempos de entrenamiento t corresponden a una ejecución en MATLAB R2026a (Apple Silicon) y varían entre ejecuciones; las métricas de error son reproducibles con las semillas fijas.

Modelo	Parám.	t (s)	RMSE CO ₂	RMSE costo	R^2 CO ₂	R^2 costo
KAN [7, 6, 2], $G = 5$, $k = 3$	486	38	0,33 kt	0,66 MUSD	0,9998	0,9953
MLP [7, 32, 32, 2]	1378	7	0,36 kt	0,36 MUSD	0,9997	0,9987
Auto-atención ($d = 8$)	2194	34	0,30 kt	0,28 MUSD	0,9998	0,9992




Figura 6: Predicción frente a valor real en el conjunto de prueba para los tres sustitutos.

y bombeo diferible f_a (1 %). Las funciones de f_v y P_w son monótonas y casi lineales (efecto proporcional), la de E_b es fuertemente no lineal en una sola arista (la batería sólo importa a través del costo) y las de f_a son planas (el bombeo es demasiado pequeño para mover los objetivos), lo que coincide con la lectura de la Tabla 4. El mapa de auto-atención (Figura 8) es consistente: la fila y la columna de f_v concentran los pesos (autoatención 0,35; $f_a \rightarrow f_v$ 0,25), es decir, el modelo aprende que las interacciones relevantes pasan por la carga inteligente, y P_h^+ atiende sobre todo a P_{pv} (0,21), reflejando la complementariedad diaria hidro-solar.




Figura 7: Funciones de activación aprendidas en las aristas de la primera capa de la KAN (una curva por neurona oculta) e importancia relativa de cada variable de decisión.

Optimización asistida. NSGA-II ejecutado sobre la KAN y re-evaluado con el modelo completo recupera el **94,7 % del hipervolumen** del frente real (948 vs. 1001) con 648 evaluaciones reales (600 de entrenamiento + 48 de re-evaluación) en lugar de 2928, un ahorro del 78 % (Figura 9). En el modelo hub, cuyo costo por evaluación es de milisegundos, el tiempo total es mayor por el entrenamiento; pero proyectado al modelo EnergyPLAN de Trento (4,3 s por evaluación [4]) el ahorro equivaldría a 2,7 h por corrida, y en los modelos con restricciones de red y Monte Carlo del PT3 la ventaja escala linealmente. El sesgo observado (el frente asistido queda 1–2 MUSD por encima en la zona intermedia) se corrige con el esquema estándar de re-entrenamiento incremental [17] o con la optimización bayesiana ya validada en [4].

5.4. Dream Optimization Algorithm

En el problema restringido (costo mínimo con $J_1 \leq 415$ kt), con presupuesto de 3000 evaluaciones y 6 semillas, DOA obtiene $J = 90,86 \pm 0,10$ MUSD, estadísticamente equivalente a PSO ($90,80 \pm 0,001$) y mejor que GA ($93,38 \pm 1,72$) y que la búsqueda aleatoria ($100,2 \pm 3,5$) (Tabla 7, Figura 10). La mejor solución DOA (283–287 MW FV, 150 MW eólica, sin batería, 30 MW mini-hidro, $f_v = 0,74$, $f_g = 0$; $\text{CO}_2 = 415,0$ kt, costo 90,81 MUSD) coincide con la del frente NSGA-II en ese nivel de emisiones, lo que confirma la consistencia entre métodos. DOA converge más rápido que GA (alcanza 91 MUSD en ≈ 700 evaluaciones frente a >3000 de GA) y con menor dispersión entre semillas que GA, aunque PSO lo iguala en este problema suave de 7 variables; la ventaja de DOA reportada por sus autores se manifiesta en problemas




Figura 8: Pesos medios de auto-atención entre variables de decisión (conjunto de prueba).




Figura 9: Frente 2030 con el modelo completo frente al frente obtenido sobre el sustituto KAN y re-evaluado con el modelo completo.

multimodales de mayor dimensión [14], como serán los del PT3 (escenarios urbano/rural con decenas de variables).

Tabla 7: Problema mono-objetivo restringido (2030): estadísticas sobre 6 semillas, 3000 evaluaciones.

Algoritmo	J media	desv. est.	J mín.	J máx.
DOA (reimplementación)	90,86	0,096	90,81	91,05
GA (<i>Global Optimization Toolbox</i>)	93,38	1,717	91,70	95,52
PSO (<i>Global Optimization Toolbox</i>)	90,80	0,001	90,79	90,80
Búsqueda aleatoria	100,25	3,478	95,11	104,22




Figura 10: Convergencia media de los cuatro algoritmos (6 semillas).

En la construcción del frente por escalarización de Tchebycheff, 12 corridas independientes de DOA (3168 evaluaciones en total) alcanzan el **95,3 % del hipervolumen** de NSGA-II (1047 vs. 1099 con 2928 evaluaciones), Figura 11. Los puntos DOA se ubican sobre el frente en la zona de bajo costo y presentan dispersión en la zona de bajo CO₂, donde la escalarización con presupuesto pequeño (264 evaluaciones por peso) converge parcialmente. Este resultado sugiere un uso práctico del DOA en el proyecto: **refinamiento local** de soluciones de interés del frente (p.ej. la de compromiso) y **sintonización de hiperparámetros** del EMS, tareas mono-objetivo en las que su simplicidad (sin operadores de cruce ni parámetros de inercia) es una ventaja.

5.5. EMS con atención temporal

La Tabla 8 compara, para la solución de compromiso 2030 de la versión 1 (255 MW FV, 150 MW eólica, 30 MW mini-hidro, $f_a = 0,33$, $f_v = 0,84$), el llenado de valles con la atención temporal antes y después de sintonizar θ con DOA (320 evaluaciones). Con las señales del año tipo (factor de emisión y precio del SNI con variación mensual y ruido) la atención sintonizada iguala al llenado de valles (CO₂ 417,7 vs. 417,8 kt; costo 90,10 vs. 90,22 MUSD, $-0,13\%$) y la resiliencia bajo sequía es idéntica (ENS 10,99 GWh); con parámetros no sintonizados es ligeramente peor ($+0,4\%$ en CO₂). Se construyó además un escenario con **tarifa horaria** (valle 0–6 h $\times 0,7$, punta 18–22 h $\times 1,6$) y **factor de emisión marginal horario** (mediodía $\times 0,8$, punta $\times 1,4$): la ganancia sigue siendo marginal ($-0,23\%$ en costo, $+0,07\%$ en CO₂). La explicación es cuantitativa: la energía flexible es sólo el 4 % de la demanda anual (bombeo diferible 4 GWh + carga inteligente 65 GWh) y el llenado de valles ya la sitúa en las horas




Figura 11: Frente 2030: NSGA-II frente a DOA con escalarización de Tchebycheff (12 pesos).

nocturnas, que coinciden con el valle tarifario; el margen de mejora es pequeño por construcción. El resultado es útil en dos sentidos: (i) valida que la heurística de la versión 1 es casi óptima para el caso actual, y (ii) deja lista una política parametrizada y sintonizable que *generaliza* el llenado de valles y cuyo beneficio crecerá con la penetración de VE (2050: 327 GWh de movilidad), con tarifas horarias reales de ARCERNNR y con señales de red (congestión de alimentadores) que el llenado de valles no puede incorporar.

Tabla 8: EMS: llenado de valles frente a atención temporal (solución de compromiso 2030 de la versión 1).

Señales	EMS	CO ₂ (kt)	Costo (MUSD)	Import. (GWh)	ENS se
Año tipo	Llenado de valles	417,76	90,22	690,2	
	Atención (θ por defecto)	419,42	90,84	702,5	
	Atención sintonizada (DOA)	417,71	90,10	690,1	
Tarifa y FE horarios	Llenado de valles	436,73	101,52	690,2	
	Atención (θ por defecto)	436,80	101,47	691,2	
	Atención sintonizada (DOA)	437,05	101,29	690,5	

6. Discusión: flujo de trabajo propuesto para el entregable PT2

Los experimentos permiten fijar, con evidencia, la arquitectura del EMS y de la cadena de planificación que se publicará en GitHub en febrero de 2027:

1. **Datos** → **escenarios**. Base de datos PT1 (CENTROSUR, ETAPA, ANT/EMOV, recurso) → autoencoder de días → generador latente jerárquico. Criterio de aceptación: NRMSE < 15 % y Pearson > 0,85 frente a mediciones (Formulario 2) y NRMSE del autoencoder ≤ PCA en todas las variables con datos reales.
2. **Modelo vectorial**. **renon_hub** calibrado; salida estándar: objetivos, $\bar{C}$, indicadores por vector y κ . Extensión inmediata: restricciones de red de distribución y separación urbano/rural (Tarqui, Victoria del Portete, Cumbe).




Figura 12: EMS con atención temporal: asignación de cargas flexibles en un día húmedo y uno de estiaje con tarifa horaria (arriba), cambio relativo frente al llenado de valles (abajo izq.) y ENS bajo sequía extrema (abajo der.).

3. **Sustituto.** KAN como sustituto *interpretable* para análisis de sensibilidad y talleres con actores (las curvas ϕ_{ij} son comunicables a CENTROSUR/ETAPA); MLP o atención como sustituto de *precisión* dentro del optimizador; re-entrenamiento incremental.
4. **Optimización.** NSGA-II (referencia) y optimización bayesiana qNEHVI para el frente [15, 4]; DOA para refinamiento local y para sintonizar el EMS; tercer objetivo o restricción de resiliencia (ENS bajo sequía) para valorar V2G y almacenamiento.
5. **Operación.** EMS jerárquico con política de atención temporal sintonizada por escenario tarifario; línea base de llenado de valles como control.
6. **Validación (PT4).** Métricas NRMSE/Pearson y comparación con los casos de Dinamarca, Alemania e Italia (Trento ya replicado).

Limitaciones. (i) Todos los resultados usan perfiles sintéticos y parámetros provinciales estimados; los valores absolutos cambiarán con la calibración del PT1. (ii) La KAN y el DOA son reimplementaciones propias, no las bibliotecas de los autores; los hiperparámetros no fueron optimizados. (iii) El autoencoder se evaluó con una sola arquitectura y semilla. (iv) El V2G se modeló con una ventana fija y sin degradación dependiente de la profundidad de descarga. (v) Las comparaciones de tiempo de cómputo no son concluyentes para un modelo de milisegundos por evaluación; su lectura correcta es en número de evaluaciones.

7. Plan de trabajo extendido (Sprints 4–8)

Tabla 9: Actividades propuestas para el PT2 con base en este reporte.

Sprint	Actividad	Responsable	Producto
4 (oct 2026)	Calibración de <code>renon_hub</code> con series reales; validación NRMSE/Pearson; autoencoder vs. PCA con datos reales	TINV, INV2, AI	Reporte de calibración
5 (nov 2026)	Restricciones de red y partición urbano/rural; tercer objetivo de resiliencia; V2G con degradación	TINV, INV1	<code>renon_hub</code> v3
6 (dic 2026)	Sustituto KAN/atención con re-entrenamiento incremental; qNEHVI en MATLAB o Python (BoTorch)	TINV, INV1	Módulo de optimización
7 (ene 2027)	EMS de atención con tarifas ARCERNR y señales de red; sintonización DOA; pruebas en supercomputador DEET	TINV, DP	EMS documentado
8 (feb 2027)	Documentación, pruebas unitarias, licencia MIT, publicación en GitHub; sesión de retroalimentación con actores	TINV, DP, INV2	Entregable PT2

8. Conclusiones

1. La formulación vectorial (concentrador energético) del modelo ReNoN es compatible con la versión 1 —la reproduce exactamente— y añade la huella vectorial $\bar{C}$, los indicadores por vector y el índice de acoplamiento κ , que hacen legible la transición: el SNI pasa de cubrir el 74 % de la electricidad en 2024 al 42 % en 2030 y al 39 % en 2050, y la movilidad electrificada de 2050 se alimenta 40 % de FV.

2. El V2G no es seleccionado por el optimizador en el año tipo con los costos asumidos, pero reduce 38 % la energía no suministrada bajo sequía extrema; su valoración exige objetivos explícitos de resiliencia.
3. Los sustitutos KAN, MLP y de atención reproducen el modelo con $R^2 \geq 0,995$; la KAN lo hace con 486 parámetros y ofrece curvas de sensibilidad interpretables que identifican la carga inteligente de VE y la eólica como las palancas dominantes. La optimización asistida por KAN recupera el 94,7 % del hipervolumen con 78 % menos evaluaciones.
4. El DOA, reimplementado a partir de su descripción publicada, iguala a PSO y supera a GA en el problema restringido y reconstruye el 95 % del hipervolumen de NSGA-II por escalarización; su nicho en el proyecto es el refinamiento local y la sintonización del EMS.
5. El autoencoder no supera a PCA en compresión de los perfiles sintéticos (casi lineales) pero provee un generador de escenarios libre de supuestos distribucionales cuya salida coincide con el Monte Carlo paramétrico.
6. El EMS con atención temporal generaliza el llenado de valles; con la carga flexible actual (4 % de la demanda) su ganancia es marginal ($\leq 0,3\%$), lo que valida la heurística de la versión 1 y acota el beneficio esperable a escenarios con mayor electrificación y tarifas horarias.

Referencias

- [1] GIEEC–DEET, “Formulario 2: Propuesta de proyecto v2 — Transición energética sostenible en Azuay–Ecuador mediante infraestructuras integradas,” XXII Concurso Universitario de Proyectos de Investigación, VIUC, Universidad de Cuenca, ene. 2026.
- [2] GIEEC–DEET, “Propuesta técnica de solución: modelo multivectorial ReNoN para la transición energética sostenible en Azuay–Ecuador. Reporte técnico de diseño, implementación y simulación en MATLAB (v1),” Universidad de Cuenca, jul. 2026. Disponible en <https://github.com/ismael-minchala/renon-azuay>.
- [3] M. Ortega Ortega, L. I. Minchala y P. Arévalo Cordero, “Structural vulnerabilities and GHG emissions in Ecuador’s electricity generation (2003–2024): A diagnostic approach,” *Electronics*, vol. 15, no. 16, art. 3697, 2026. doi:10.3390/electronics15163697.
- [4] B. Loza, “Replicación de la metodología EnergyPLAN+MOEA y optimización bayesiana para la planificación 2030/2050 (caso Trento),” Reporte de avance PT2, Proyecto ReNoN–Azuay, Universidad de Cuenca, sep. 2026.
- [5] D. Viesi, L. Crema, M. S. Mahbub, A. Verones, R. Brunelli, P. Baggio, M. Fauri, D. Prada, A. Bello, B. Nodari, S. Silvestri y M. Tomasi, “Integrated and dynamic energy modelling of a regional system: A cost-optimized approach in the deep decarbonisation of the Province of Trento (Italy),” *Energy*, vol. 209, art. 118378, 2020. doi:10.1016/j.energy.2020.118378.
- [6] H. Lund, J. Z. Thellufsen, P. A. Østergaard, P. Sorknæs, I. R. Skov y B. V. Mathiesen, “EnergyPLAN – Advanced analysis of smart energy systems,” *Smart Energy*, vol. 1, art. 100007, 2021. doi:10.1016/j.segy.2021.100007.
- [7] M. Geidl, G. Koeppl, P. Favre-Perrod, B. Klöckl, G. Andersson y K. Fröhlich, “Energy hubs for the future,” *IEEE Power and Energy Magazine*, vol. 5, no. 1, pp. 24–30, 2007. doi:10.1109/MPAE.2007.264850.

- [8] M. Geidl y G. Andersson, “Optimal power flow of multiple energy carriers,” *IEEE Transactions on Power Systems*, vol. 22, no. 1, pp. 145–155, 2007. doi:10.1109/TPWRS.2006.888988.
- [9] P. Mancarella, “MES (multi-energy systems): An overview of concepts and evaluation models,” *Energy*, vol. 65, pp. 1–17, 2014. doi:10.1016/j.energy.2013.10.041.
- [10] G. Chicco y P. Mancarella, “Distributed multi-generation: A comprehensive view,” *Renewable and Sustainable Energy Reviews*, vol. 13, no. 3, pp. 535–551, 2009. doi:10.1016/j.rser.2007.11.014.
- [11] W. Kempton y J. Tomić, “Vehicle-to-grid power fundamentals: Calculating capacity and net revenue,” *Journal of Power Sources*, vol. 144, no. 1, pp. 268–279, 2005. doi:10.1016/j.jpowsour.2004.12.022.
- [12] K. Deb, A. Pratap, S. Agarwal y T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: NSGA-II,” *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182–197, 2002. doi:10.1109/4235.996017.
- [13] E. Zitzler y L. Thiele, “Multiobjective evolutionary algorithms: A comparative case study and the strength Pareto approach,” *IEEE Transactions on Evolutionary Computation*, vol. 3, no. 4, pp. 257–271, 1999. doi:10.1109/4235.797969.
- [14] Y. Lang y Y. Gao, “Dream Optimization Algorithm (DOA): A novel metaheuristic optimization algorithm inspired by human dreams and its applications to real-world engineering problems,” *Computer Methods in Applied Mechanics and Engineering*, vol. 436, art. 117718, 2025. doi:10.1016/j.cma.2024.117718.
- [15] S. Daulton, M. Balandat y E. Bakshy, “Parallel Bayesian optimization of multiple noisy objectives with expected hypervolume improvement,” en *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*, 2021. arXiv:2105.08195 (doi:10.48550/arXiv.2105.08195).
- [16] Y. Ozaki, Y. Tanigaki, S. Watanabe y M. Onishi, “Multiobjective tree-structured Parzen estimator for computationally expensive optimization problems,” en *Proc. Genetic and Evolutionary Computation Conference (GECCO ’20)*, pp. 533–541, 2020. doi:10.1145/3377930.3389817.
- [17] Y. Jin, “Surrogate-assisted evolutionary computation: Recent advances and future challenges,” *Swarm and Evolutionary Computation*, vol. 1, no. 2, pp. 61–70, 2011. doi:10.1016/j.swevo.2011.05.001.
- [18] M. D. McKay, R. J. Beckman y W. J. Conover, “A comparison of three methods for selecting values of input variables in the analysis of output from a computer code,” *Technometrics*, vol. 21, no. 2, pp. 239–245, 1979. doi:10.1080/00401706.1979.10489755.
- [19] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou y M. Tegmark, “KAN: Kolmogorov–Arnold Networks,” en *International Conference on Learning Representations (ICLR 2025)*, 2025. arXiv:2404.19756 (doi:10.48550/arXiv.2404.19756).
- [20] C. J. Vaca-Rubio, L. Blanco, R. Pereira y M. Caus, “Kolmogorov–Arnold Networks (KANs) for time series analysis,” 2024. arXiv:2405.08790 (doi:10.48550/arXiv.2405.08790).
- [21] G. E. Hinton y R. R. Salakhutdinov, “Reducing the dimensionality of data with neural networks,” *Science*, vol. 313, no. 5786, pp. 504–507, 2006. doi:10.1126/science.1127647.

- [22] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin, “Attention is all you need,” en *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017. arXiv:1706.03762 (doi:10.48550/arXiv.1706.03762).
- [23] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong y W. Zhang, “Informer: Beyond efficient Transformer for long sequence time-series forecasting,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 12, pp. 11106–11115, 2021. doi:10.1609/aaai.v35i12.17325.

Reproducibilidad: el código MATLAB de esta versión está en `code/analysis/propuesta_tecnica/matlab_v2/` del repositorio <https://github.com/ismael-minchala/renon-azuay>. El script `reproduce_report_v2` ejecuta en orden `s1_hub`, `s2_autoencoder`, `s3_surrogates`, `s4_doa` y `s5_attention_ems` con semillas fijas (MATLAB R2026a; requiere Deep Learning, Optimization, Global Optimization y Statistics and Machine Learning Toolbox; Parallel Computing Toolbox opcional). Las tablas CSV están en `resultados_v2/`, las figuras en `reporte/figs_v2/` y las pruebas de regresión en `tests/`. El código del modelo de la versión 1 (`matlab/`) no se modificó.